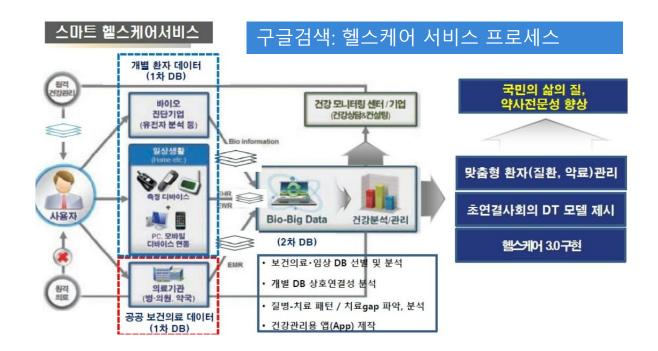
# 파이썬 자료형

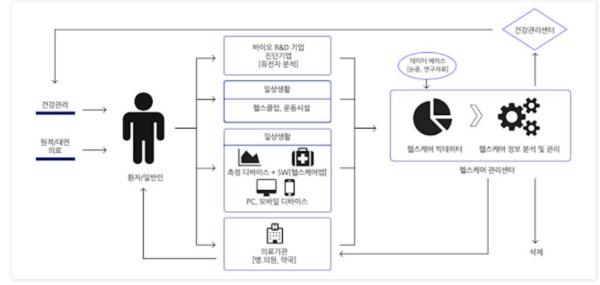
[부성순] bakpak@empas.com

## 입력데이터

- csv, excel,txt, json, xml등 파일데이터 파일에 따라 전문 읽기 명령어로 처리
  - (1) 내pc(로컬)자료
  - (2) 네트워크로 연결된 다른pc자료
- **데이터베이스 서버의 데이터** 데이터베이스전문처리명령어 실행(예: SQL)
  - (1) 내pc(로컬)자료
  - (2) 네트워크로 연결된 다른 pc자료
  - (3) 네트워크 데이터베이스 서버
- 웹페이지 자료 크롤링(웹스크래핑)으로 필요한 자료를 가져오거나 API를 이용하여 허가받고 자료를 연결함
  - (1) 인터넷상의 웹페이지 자료의 구조를 보고
  - (2) 다른네트워크의 저장된 자료셋을 연결하여서
  - 의료정보 표준화 https://www.aitimes.com/news/articleView.html?idxno=140168 https://aifactory.space/task/2290/discussion/280

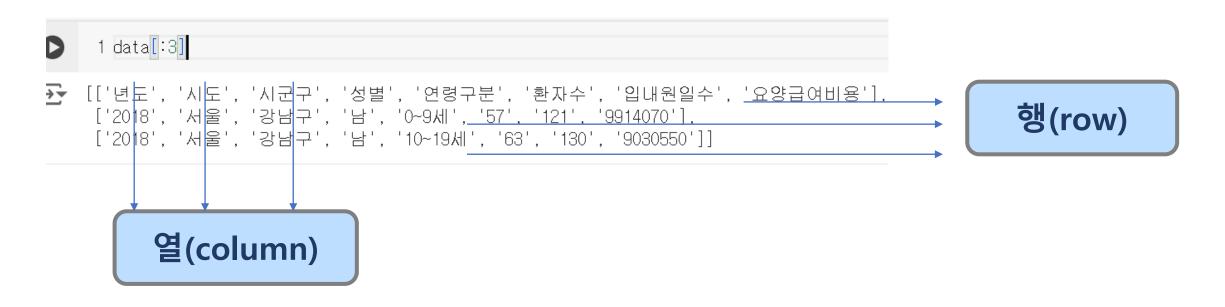
구글검색: '의료데이터 표준화 json'





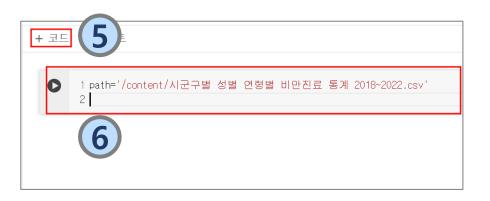
#### [무작정 해보기] csv, txt 와 json 파일을 파이썬에서 처리하고자함

CSV는 몇 가지 필드를 쉼표(, )로 구분한 텍스트 데이터 및 텍스트 파일이며 row--> enter단위로 자료를 가져옴









[1] csv자료를 with 구문으로 읽을수 있음. 숫자,문자가 섞여있는 경우는 pandas 모듈이 더 편리함

```
1 import csv
 3 path = '/content/시군구별 성별 연령별 비만진료 통계 2018~2022.csv'
 5 data=[] #빈공간리스트 준비
6 # CSV 파일 읽기
7 with open(path, 'r', encoding='euc-kr') as file:
      reader = csv.reader(file)
10
     # 첫 번째 줄은 헤더로 처리
     header = next(reader) # 이코드때문에 data[이이 제목이 되지 않고, 자료가됨
12
     # 데이터 출력 (옵션)
14
     for row in reader:
         data.append(row) # 각 행 출력 예시
15
16
17 print('end')
```

🗼 end

```
] 1 data[:3]

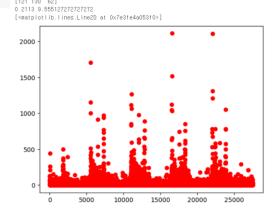
▶ [['2018', '서울', '강남구', '남', '0~9세', '57', '121', '9914070'],
['2018', '서울', '강남구', '남', '10~19세', '63', '130', '9030550'],
['2018', '서울', '강남구', '남', '20~29세', '34', '62', '5063090']]

■ 1 2 3 4 5 6 7

년도 시도 시군구 성별 연령구분 환자수 입내원일수 요양급여비용
```

[2] csv 자료중 '입내원일수 ' (6열) 자료로 기본적인 통계와, 차트 작성

```
1 import numpy as np
2 dataArry=np.array(data)
3 value=dataArry[:,6].astype('int') #숫자형변환
4
5 print(value[:3]) # 0,1,2 3개만
6
7 # 데이터의 최저, 최고, 평균값 출력
8 print(np.min(value), np.max(value), np.mean(value))
9
10 # 차트 출력
11 import matplotlib.pyplot as plt
12 plt.plot(value, 'ro') # r:빨강, o:동그라미 출력
```



[무작정 해보기] csv, txt 와 json 파일을 파이썬에서 처리하고자함

(참고) [3] 환자수 (5번열), 입내원일수(6번열), 요양급여비용(7번열) 의 값을 반복하여서 처리하고자 할때는 함수로 작업하면 편리함

```
2 ### [함수]
3 ### 자료의 열 값을 넣으면
4 ### 숫자로 변경하고, 기본 통계를 출력, 차트작성
6 import numpy as np
7 import matplotlib.pyplot as plt
8 def my(columnBun):
9
   dataArry=np.array(data)
   value=dataArry[:,columnBun].astype('int') #숫자형변환
12
   print(value[:3]) # 0,1,2 3개만
13
14
15
   # 데이터의 최저, 최고, 평균값 출력
   print(np.min(value), np.max(value), np.mean(value))
17
   # 차트 출력
18
19
   plt.plot(value, 'ro') # r:빨강, o:동그라미 출력
21
22 \text{ my}(7)
```



https://developer.mozilla.org/ko/docs/Learn/HTML/Introduction\_to\_HTML/Getting\_started

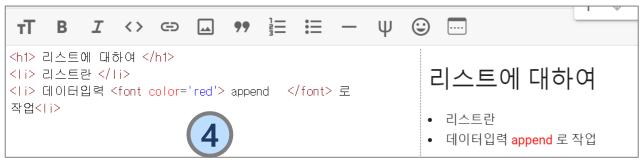
HTML (Hypertext Markup Language,하이퍼텍스트 마크업 언어)는 프로그래밍 언어는 아니고, 우리가 보는 웹페이지가 어떻게 구조화되어 있는지 브라우저로 하여금 알 수 있도록 하는 마크업 언어

**마크업 언어**란 태그 등을 이용해서 문서나 데이터의 구조를 표현하는 **언어**의 한 가지로서 '마크(Mark)'로 둘러쌓인, 문서의 구조를 정의하는 **언어임.** 









## 강의내용

- 파이썬 List

- 파이썬 딕셔너리

- 파이썬 Numpy

https://wikidocs.net/14

https://wikidocs.net/16



## 파이썬에서 리스트

▶ 파이썬에서 리스트(list)란 대괄호([, ])로 감싸서 나타내며, 안에는 0개 이상의 원소가 저장될 수 있음

```
예) a=[] 또는 a = list(), a=[1], a=['마라'], a=[20,30,40]
```

- ▶ 원소들이 연속적으로 저장되는 형태의 자료형예) a= [ 20,30], a=[20,30, [1,2,3,]]
- ▶ 이때 저장되는 요소들이 모두 같은 자료형일 필요는 없다 \*참고 Array(행렬)은 반드시 갯수를 통일하고, 자료형을 통일한다. 숫자,문자가 들어가면 모두 문자 처리함

```
예) a=[

['서울',20,30]

['부산',15]

['제주',25,30,50]
```



## 파이썬 딕셔너리 https://wikidocs.net/16#\_1

- ▶ 'key': value 값으로 구성됨 {} 안에 표현함
- ▶ .json 은 딕셔너리 형식임

#### 서울시 공공데이터 접속하여

```
import urllib.request
import json
url='http://openapi.seoul.go.kr:8088/sample/json/SeoulPublicLibraryInfo/1/5/'
plainText=urllib.request.urlopen(url).read().decode()
plainText
jsonData=json.loads(plainText)
jsonData
libData=jsonData.get('SeoulPublicLibraryInfo').get('row')
import pandas as pd
df=pd.DataFrame(libData)
df.head()
  LBRRY_SEQ_NO LBRRY_NAME GU_CODE CODE_VALUE ADRES TEL_NO
                                                                                                      OP_TIME FDRM_CL
                                                                                         HMPG URL
                                                 서울
                                                                                                        평일:
```

```
0
     1 ### 만약 모든 자료가 아니라 필요한 열만 넘기고자 한다면
     2 dataList=[]
     3 for item in libData:
        name=item.get('LBRRY_NAME')
        tel=item.get('TEL_NO')
        dataList.append(['name':name,
                        'tel':tel})
     8 pd.DataFrame(dataList)
\overline{\mathbf{T}}
                                        tel
                    name
         강남구립못골도서관
                           02-459-5522
       강남역삼푸른솔도서관 02-2051-1178
           개포하늘꿈도서관
    2
                          02-451-1511
                논현도서관 02-3443-7650
```

```
1 #df[['TEL_NO','HMPG_URL']] # df.
2 df.iloc[:, [6,5]]

v 0.0s

HMI

0 http://library.gangnam.go.kr/ysplib/ide.
```

```
4
1 #·서울시·도서관·전체·갯수는?
2 len(df)
✓ 0.0s
206
```

#### [사전지식] <mark>공공데이터란?</mark>

open API란?

- (1) 서울시 공공데이터에 접속 <a href="https://data.seoul.go.kr/">https://data.seoul.go.kr/</a>
- (2) 회원가입 및 openAPI키 발급받기

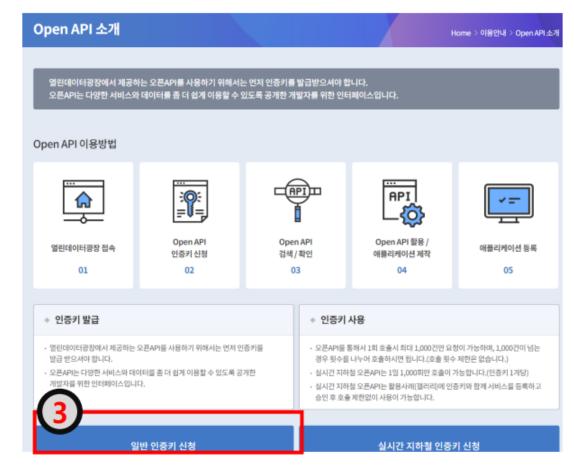
#### 서울시 공공데이터

- 공공데이터
- OpenAPI



- (3) 일반 인증키 신청
- (4) 인증키관리에서 본인인증키 복사







- [5] OpenAPI
- [6] 샘플 URL 복사해서



#### 제공되는 샘플

http://openapi.seoul.go.kr:8088/(인증키)/xml/SeoulPublicLibraryInfo/1/5/

샘플인증키

78734b626c62616b35344947554c45

코드변환 url을 상황에 따라 나누어서 변환해야 하는 경우가 많음으로 아래와 같이 url을 나누어작업함

```
6 v import urllib.request
7 import json
8
9 apiKey='78734b626c62616b35344947554c45'
10 url='http://openapi.seoul.go.kr:8088/'
11 url+=apiKey
12 url+='/json/SeoulPublicLibraryInfo/1/5/'
13 print(url)
14
v 0.0s

At Man 206개이지만
At Ma
```

url이 잘 출력되는지 확인 용

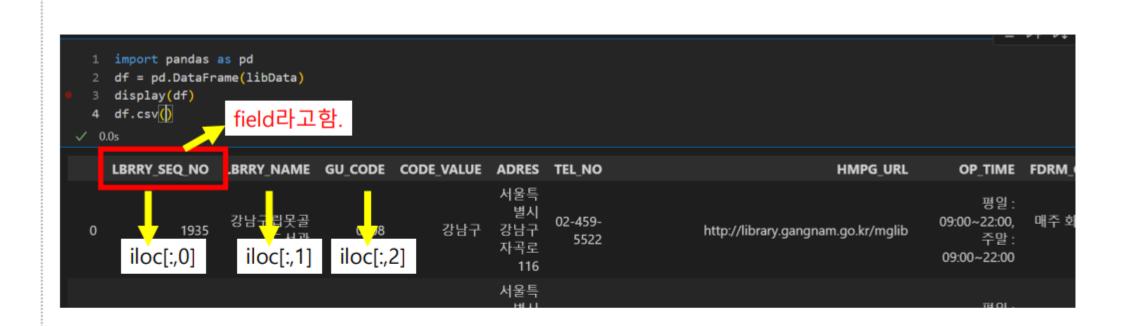
```
{
    "SeoulPublicLibraryInfo": {
        "list_total_count": 206,
        "RESULT": {
            "CODE": "INFO-000",
            "MESSAGE": "정상 처리되었습니다"
        },
        "row": [
            {
                "LBRRY_SEO_NO": "1935",
                "LBRRY_NAME": "강남구립못골도서관",
                "GU_CODE": "0008",
                "CODE_VALUE": "강남구",
                "ADRES": "서울특별시 강남구 자골로 116"
```

```
import urllib.request
import json

api_Key='78734b626c62616b35344947554c45'
url='http://openapi.seoul.go.kr:8088/'
url+=api_Key
url+='/json/SeoulPublicLibraryInfo/1/206/'
plainText=urllib.request.urlopen(url).read().decode()
jsonData=json.loads(plainText)
libData=jsonData.get('SeoulPublicLibraryInfo').get('row')
```

데이터셋의 갯수는 직접 확인하여서 206개로 변경해도 되고 계속 변동되는 자료라면 List\_total\_count값으로 다시 연결할수는 있지만 여기서는 갯수를 직접 입력하는 코드로 작업하고자 함.

import pandas as pd
df = pd.DataFrame(libData)
display(df)



df['TEL\_NO'] 하면 전화번호 필드 데이터만 출력됨 df[['TEL\_NO','ADDRES']] 하면 전화번호와 주소 필드가 출력됨

df.iloc[행번호,열번호], 행번호 열번호 위치에 : 이 있으면 모든 자료란 뜻

df.iloc[:,5] 는 전체행, 5열임 / 전화번호 필드 출력됨 df.iloc[:, [5,4]]는 전체행, 5열/4열 출력 (전화번호와 주소 필드 출력됨)

#### (참고) csv를 리스트로 읽은 자료를 json으로 변경

```
2 ### 데이터를 dict로 구성하면 추후 자료 확인이 쉬움
4 items=[]
5 for row in data:
  val={['년도': row[0],
      '시도': row[1],
      '시군구': row[2],
8
     - '성별': row[3].
    '연령구분': row[4].
10
    '환자수': row[5],
12
      '입내원일수': row[6],
13
      '요양급여비용': row[7]
14
  items.append(val)
16 items[:2]
```

```
[{'년도': '2018',
 '시도': '서울',
 '시군구': '강남구',
 '성별': '남',
 '연령구분': '0~9세',
 '환자수': '57',
 '입내원일수': '121',
 '요양급여비용': '9914070'}.
{'년도': '2018',
 '시도': '서울',
 '시군구': '강남구',
 '성별': '남',
 '연령구분': '10~19세',
 '환자수': '63',
 '입내원일수': '130',
 '요양급여비용': '9030550'}]
```



## 파이썬에서 Numpy

- ▶ Array (행렬) 이며, 행(row)와 열(column)으로 이루어짐. 반드시 갯수와 성격이 같은 자료가 되어야함.
- ▶ 행렬을 만드는 이유는 계산을 빠르게 하기위함임.

자료의 형식은 좌측에 있는 엑셀자료와 같음을 인지해야함.

#### 작업1) 자료불러와 제목과 자료 분리

신규회원=[['지점','1월','2월','3월'], ['A',1,2,5], ['B',3,4,1], ['C',4,1,1]]

data

header

header=신규회원[0] data=신규회원[1:] data

	Α	В	С	D
	지점	1월	2월	3월
1	Α	1	2	5
3	В	3	4	1
4	С	4	1	1

### 작업2) 작업하기 편리하게 인원수만 분리함

import numpy as np data=np.array(data) 인원수=data[:,1:].astype(np.uint8) 인원수

1	^data[:,0]	data[:,1]	ー data[:,2]	data[:3]
2	А	1	2	5
3	В	3	4	1
4	С	4	1	1
_				

## 작업3) 인원수 자료중 1월에만 100을 더하고자 함. Numpy 자료임으로 '브로드 캐스트 ' 가능함

\*브로드캐스트: 각 인덱스마다 +100을 하지 않고 행,열 단위로 한번에 작업하는 기능을 의미 넘파이 자료만 브로드캐스트 가능함

1월		2월	3월	
인원	원수[:,0]	인원수[:,1]	인원수[:,2]	
	А	В	С	
1	1	2	5	
2	3	4	1	
3	4	1	1	

```
##############################
# 1월에만 +100을 하고자할때
 #############################
인원수[:,0]+=100
 인원수
0s
([[101, 2, 5],
 [103, 4, 1],
 [104, 1, 1]], dtype=uint8)
```

#### 작업4) 2월자료에만 \*2.3 을 하고자 함. dtype변경을 하지 않으면 정수자료임으로 정수만 출력됨

\*형은 맨처음 입력할때 0~255의 정수만 입력하였음으로 자동 설정된 것임 구글검색 '넘파이 형선언', '넘파이 형변환 '

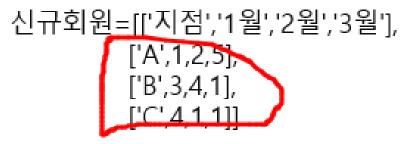
```
신규회원=[['지점','1월','2월','3월'],
['A',1,2,5],
['B',3,4,1],
['C',4,1,1]]
```

```
# 2월에만 *2.3을 하고자할때
    # dtype이 int라 소수점이하 절사됨
    ###################################
    인원수[:,1]=인원수[:,1]*2.5
  6 인원수
   0.0s
array([[101, 5, 5],
          10, 1],
     [103,
     [104, 2, 1]], dtype=uint8)
                  정수형중 0~255까지 숫자
```

#### 작업5) C지점에만 전체 -100을 하고자 할때

```
#####################################
   2 # C지점에만 전체 -100을 하고자 할떄
     ####################################
   4 인원수[2,:]=인원수[2,:]-100
   5 인원수
 ✓ 0.0s
array([[101., 12.5, 5.],
      [103., 25., 1.],
      [ 4., -95., -99.]], dtype=float32)
```

	Α	В	С
인원수[0, :] 🕶	1	2	5
인원수[1, :] 🔫	3	4	1
인원수[2, :] 🖘	4	1	1
<u> </u>			



## 작업6) 인덱싱 마무리

1 ####################################
✓ 0.0s
array([[101., 50., 5.], [103., 50., 100.], [ 4., 50., -99.]], dtype=float32)

	1월		2월	3월
		А	В	С
A	1	0,0	0,1	0,2
В	2	1,0	1,1	1,2
C	3	2,0	2,1	2,2

#### 작업7) Numpy 조건문

이 PT 자 보고난뒤에 별도로 'Numpy 조건문' 으로 검색하여 조건문을 인지합니다. 2개이상의 조건을 동시에 만족하는 And, 조건중 한 개만 만족하는 Or에 대한 문법도 확인합니다.

```
2 # 자료중 50이상인 값만 999로 변경하고자할때
     ##################################
  4 인원수[인원수[:,:]>50]=999
  5 인원수
 ✓ 0.0s
array([[999., 50., 5.],
     [999., 50., 999.],
     [ 4., 50., -99.]], dtype=float32)
```

```
*************************************
  2 # 위의 공식은 np.where 로 대체될수 있음
    인원수[np.where(인원수>50)]=999
    인원수
✓ 0.0s
array([[999., 50., 5.],
     [999., 50., 999.],
     [ 4., 50., -99.]], dtype=float32)
```

#### 작업8) Numpy를 이용하면 편리한 계산식 (브로드캐스트와 동시와 계산식도 제공됨)

#### <u>브로드 캐스트</u> 및 연산식(합,평균,최대,최소등) 제공함

np.mean→평균

```
1 ### 총인원수 몇명인지 알고 싶을때
2 ### 인원수당*인센티브한자료의 합
3 ### 평균등 계산
4 np.sum(인원수), np.sum(인원수*5000), np.mean(인원수), np.mean(인원수*5000)

✓ 0.0s

(3057.0, 15285000.0, 339.66666, 1698333.4)
```

#### 작업9) 월별인센티브를 넣어서 각 행에 곱셈 가능함.

```
###################################
  2 ## 월별 인센티브 가 다를때
   4 월별인센티브=[20,
  5
               15] #1월은 20, 2월은 50, 3월은 15일떄
  6
    인원수,월별인센티브,인원수*월별인센티브
✓ 0.0s
(array([[999., 50., 5.],
      [999., 50., 999.],
      [ 4., 50., -99.]], dtype=float32),
[20, 50, 15],
array([[19980., 2500., 75.],
      [19980., 2500., 14985.],
      [ 80., 2500., -1485.]]))
```

Array shape 가 통일되지 않으면 연산되지 않는 문제

#### 작업10) 내적곱(np.dot) 에 대한 이해 : 곱셈한뒤 그 곱셈의 값을 행단위로 더하는것

A,B,C 지점에 월별 인센티브를 더해서 1,2,3월의 총합을 구하고자 할때 계산식을 나누어 작업해도 되지만 (곱셈후, 행단위의 합계) np.dot 기능을 이용하여 한번에 작업가능함

#### 인원수

#### 각월별인센티브

#### 인원수\*각월별인센티브

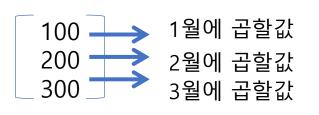
내적곱결과

2600

1월 2월 3월

3, 4, 5 2, 3, 4

2행\***3열** 



3행\*1열

np.dot(a,b)가 되려면 반드시 a의 열과 b의 행값이 같아야함. 결과는 a의 행\* b의 열임

```
3*100, 4*200, 5*200
2*100, 3*200, 4*300
```

## 작업10) 내적곱(np.dot) 에 대한 이해 : 곱셈한뒤 그 곱셈의 값을 행단위로 더하는것

행열이 다르면 np.dot가 실행되지 않음.

```
1 \vee a = [[3,4,5],
          [2,3,4]]
      b=[[100,200,300]]
      print(np.shape(a), np.shape(b))
   6 np.dot(a,b)
 ⊗ 0.0s
(2, 3) (1, 3)
ValueError
                                            Traceback (most recent call last)
Cell In[87], <u>line 6</u>
      3 b=[[100,200,300]]
      5 print(np.shape(a), np.shape(b))
----> 6 np.dot(a,b)
ValueError: shapes (2,3) and (1,3) not aligned: 3 (dim 1) != 1 (dim 0)
```

## 작업10) 내적곱(np.dot) 에 대한 이해 : 곱셈한뒤 그 곱셈의 값을 행단위로 더하는것

이때 reshpae을 통해서 행열값을 변경하고 연산가능함.

```
1 \vee a = [[3,4,5],
               [2,3,4]]
       3 b=[[100,200,300]]
       4 c=np.reshape(b, (3,1))
       5 print(np.shape(a), np.shape(b)), np.shape(c)
       6 np.dot(a,c)
     ✓ 0.0s
88]
    (2, 3) (1, 3)
    array([[2600],
           [2000]])
```

작업11) array 끼리 추가(열단위, 행단위) 추가도 array의 shape이 일치해야함.

hstack: 열(세로로) 추가할때

```
2 ### 4,5,6월자료가 추가될때
  4 import numpy as np
  5 추가=[ [1,4,5],
     [2,2,3],
  6
        [7,8,9]]
   인원수=np.hstack((인원수,추가))
   인원수
 10
✓ 0.0s
array([[999., 50., 5., 1., 4., 5.],
     [999., 50., 999., 2., 2., 3.],
    [ 4., 50., -99., 7., 8., 9.]])
```

## 작업11) array 끼리 추가(열단위, 행단위) 추가도 array의 shape이 일치해야함.

vstack: 열(세로로) 추가할때

```
## E지점의 1월~6월자료를 추가하고자 할때
     ###############################
  4
  5 E지점=[[1,2,1,1,1,1]]
  6 np.vstack((인원수,E지점))
✓ 0.0s
array([[999., 50., 5., 1., 4., 5.],
     [999., 50., 999., 2., 2., 3.],
     [ 4., 50., -99., 7., 8., 9.],
     [1., 2., 1., 1., 1., 1.]
```